

UNIVERSIDAD
DE GRANADA

Práctica 2

Problema del portfolio

Pablo Linari Pérez

DNI: 75571079W
Grupo de prácticas: 3 (Martes 15:30-17:30)
Curso: 25/26
Correo: pablolinari@correo.ugr.es

Índice de contenidos

1 Descripción del problema 3
2 Algoritmos empleados y estructura del problema 4
2.1 Estructura del problema 4
2.2 Representación de las soluciones 4
2.3 Funciones comunes usadas por los algoritmos 5
2.4 Operadores 7
2.4.1 Operadores de cruce 7
2.4.2 Operador de selección 9
2.4.3 Operador de mutación 9
3 Estructura de los algoritmos 12
3.1 Local Search 12
3.2 Algoritmo Genético Generacional 13
3.3 Algoritmo Genético Estacionario 14
3.4 Algortimo Memético 15
3.4.1 AM-Random 15
3.4.2 AM-All 15
3.4.3 AM-Best 15
4 Estructura del código 16
4.1 Organización de archivos 16
4.2 Compilación 17
4.3 Manual de usuario: Ejecución 17
5 Experimentos y análisis de los resultados 18
5.1 Casos empleados y valores de los parámetros. 18
5.2 Resultados obtenidos 19
5.3 Boxplots de los resultados 20
6 Análisis de los resultados 21
6.1 Comportamiento de los Algorítmos Genéticos Generacionales 21
6.2 Comportamiento de los Algorítmos Genéticos Estacionarios 22
6.3 Comportamiento de los Algorítmos Meméticos 22
6.4 Mejor operador para los genéticos 22
6.5 Búsqueda Local vs Algorítmos Genéticos 22
6.6 AGE-BLα vs AGG-BLα 23
6.7 Comparación entre meméticos 23
6.8 Meméticos vs mejor AG 23
6.9 Comparación Gráfica fitness 2014-2024 (50 ejecuciones) 23
6.10 Comparación global y conclusiones 24

1 Descripción del problema

El problema que se ha escogido es el problema del portfolio, en el cual se nos da una lista de empresas de las cuales sabemos su retorno obtenido diario desde principios de 2015 hasta finales de 2025. Con estos datos necesitamos elaborar una solución indicando qué porcentaje de nuestra cartera deberíamos haber invertido en cada empresa para maximizar el beneficio de las inversiones.

En este contexto, el problema no solo busca el máximo retorno, sino que también suele considera la correlaicion entre activos teniendo esto en cuenta en las ecuaciones que se usan para maximizar el beneficio.

De esta manera podemos ajustar el programa ajustando el parametro λ de la ecuacion a maximizar para asi tener mayor o menor aversión al riesgo.

2 Algoritmos empleados y estructura del problema

2.1 Estructura del problema

Para modelar el problema del portfolio se ha usado la clase Pportfolio la cual es hija de la clase Problem que viene ya predefinnida con varios métodos virtuales , los cuales se implementan en la clase hija. Para representar el problema usando estas clases se tienen en cuenta los siguientes atributos:

- **days** : número entero de días de los que se tienen datos.
- **ncompany** : número entero de empresas de las que se tienen datos.
- **low** : mínimo porcentaje de inversión en una empresa (double).
- **high** : máximo porcentaje de inversión en una empresa (double).
- **lambda** : parámetro entero usado en el fitness.
- **data** : matriz de la libreria Eigen con valores double que contienen los beneficios diarios de cada empresa, en las columnas se representan las empresas y en las filas los dias.
- **covarianceMat** : matriz de la libreria Eigen con valores double que contiene la covarianza de las empresas.
- **logSums** : vector de la libreria Eigen con valores double que contiene la suma por columnas después de aplicar **log(valor+1)** a cada posición de la matriz.
- **ERROR** : Error permitido en la suma total del vector solución (double).

Podemos observar que se ha optado por usar la libreria Eigen de C++ para poder manejar las operaciones de matrices y vectores como la suma total , la media total , la media por columnas o por filas , multiplicación escalar a escalar, etc… . Esto hace que el código sea más compacto y fácil de seguir a la vez que más preciso y cómodo de utilizar.

También se han guardado los datos como **covarianceMat** y **logSums** que son constantes durante la ejecución del programa y solo cambian cuando cambia el archivo de entrada. Al ser valores calculados con operaciones matriciales son costosos de calcular y eso hace que el programa sea más rápido.

2.2 Representación de las soluciones

Para este problema las soluciones se representan por vectores de la biblioteca Eigen con tipo de dato double donde cada posición del vector representa la i-ésima empresa del fichero de datos de entrada , todos estos vectores deben cumplir las siguientes restricciones:

- El tamaño de la solución debe ser el mismo que el número de empresas en los datos de entrada.
- La suma de todos sus valores debe ser igual a 1.
- Cada posición del vector tiene que tener un valor entre **low** y **high**
- Puede haber posiciones del vector con valor 0(representando que en esa empresa no se invierte).

La mejor solución será aquella que consiga maximizar la función objetivo.

2.3 Funciones comunes usadas por los algoritmos

En primer lugar la función que permite cargar los datos en nuestra clase Pportfolio es una función implementada en un archivo auxiliar ya que no tiene por qué pertenecer necesariamente al problema que se plantea.Esta función lee datos de un fichero en formato CSV. Tras abrir el archivo la función descarta la primera linea con los nombre de las empresas y comienza a leer las siguientes lineas, una vez escogida una linea , se salta el string que contiene la fecha y comienza a insertar datos al vector usando como separador la coma. El código comprueba los valores de la fecha leida , si el parametro only2025 es True , solo se leen datos de 2025 , de lo contrario se leen todos los datos hasta el último día del 2024. Una vez leidos todos los datos, la matriz obtenida se convierte a una matriz Eigen para poder manejarla con más facilidad.

```
funcion LoadCSV(archivo, only2025):
  matrix data
  leer(primera_linea)
  abrir archivo
  while(leer(linea_archivo)):
    if es fecha el primer string :
      continue
    if(es fecha el primer string and not only2025):
      solo leer valores de 2014-2024
    if(es fecha el primer string and only2025):
      solo leer valores de 2025
    vector valores

    while(leer(dato)):
      if(dato no vacio):
        valores.pushback(dato)
      else:
        valores.pushback(0.0)

    data.pushback(valores)

  cerrar archivo

  if(data no vacio):
    matriz_eigen = data
  return matriz_eigen
```

Las principales funciones que se usan de la clase **Pportfolio** para implementar los algoritmos son las siguientes :

La función **createSolution** Se usa en dos algoritmos , en la Búsqueda Aleatoria para generar soluciones aleatorias y escoger finalmente la que mejor fitness tenga y en la Búsqueda Local para generar la solución desde la cual se comienza a buscar la mejor solución posible.

```
funcion createSolution():
  vector solucion;

  for i<solucion.size :
```

```
    solucion(i) = Aleatorio entre high y low


  numeroceros = Aleatorio entre 1 y solucion.size-1
  vectorindices = {0,1,2, ......,solucion.size-1}
  desordenar(vectorindices)
   ## Seleccionamos valores aleatorios que ponemos a 0
  for i<numeroceros:
    solucion(vectorindices[i])=0

  solucion = solucion/solucion.sum
  if la solucion no es valida
    fix(solucion)

  return solution;
```

```
# Pseudocódigo del arreglo de solucion
 funcion fix(solucion):
    solution = solution/solution.sum

 for i in ncompany:
   if solution(i) < low:
     solution(i) = 0
   else if solution(i) >high:
     solution(i) = this->high


 double diff = 1.0 - solution.sum
 while diff >ERROR and  no supera máximo iteraciones:
   ajustado = false

   while i < ncompany and not  ajustado:
     if solution(i) en rango [low,high):
       espacio =high - solution(i)
       if hay espacio :
         sumar diferencia y ajustado=true
        else :
         solution(i) =high
         diff =diff- espacio

   if no se ha ajustado y diferencia menor mayor que low:
     for i in ncompany and not ajustado:
       if solution(i) == 0:
         solution(i) = minimo entre diff y high
         ajustado = true

   if no se ha ajustado y la diferencia es menor que low :
     while i< ncompany and not ajustado:
       if (solution(j) > low and solution(j) + diff < high:
         solution(j) += diff
         ajustado = true

   diff = 1.0 - solution.sum
```

La solución fix se aplica cada vez que se genera una solución aleatoria para arreglarla , lo que se hace es tras normalizar la solución modificar los valores fuera de rango para que cumplan las condiciones de ser solución. Una vez hecho esto , si hace falta añadir más valor en alguna posición se añade , primero se comprueba si se puede repartir dentro de pesos que ya estén activos , de no ser así si la diferencia es mayor que el limite inferior se activa un cero de la solución. En caso de que la diferencia sea menor que el mínimo permitido se intenta distribuir la diferencia entre valores que ya estén activos y tengan un margen para ser de nuevo ajustados. Este proceso se repite hasta que la diferencia es menor que el error permitido o se sobrepasen las evaluaciones. En el código las evaluaciones permitidas son altas para que no haya problema por la precisión de las operaciones.

```
# Pseudocódigo del calculo del beneficio
 funcion profit(solution):
   return (solution * logdSums).sum #multiplicación componente a componente
```

```
# Pseudocódigo del calculo driesgo
 funcion risk(solution):
   return (solution.transpose * covarianceMat * solution);
#devuelve un número resultado de las dimensiones  1xn * nxn *nx1
```

```
# Pseudocódigo del calculo del fitness
 funcion fitness(solution):
   return (profit - lambda*risk);
#devuelve un número resultado de las dimensiones  1xn * nxn *nx1
```

El principal objetivo de los algoritmos es maximizar la función fitness , la cual trata de maximizar el beneficio y minimizar el riesgo en una sola fórmula.El parámetro lambda se usará a modo de ajuste , cuando más alto sea su valor el algoritmo valorará mejor soluciones con poco beneficio pero que sean seguras , es decir que tengan poco riesgo , mientras que cuanto más cercano a 0 sea lambda , el algoritmo valorará mejor las soluciones con máximo beneficio posible , ignorando el riesgo.

2.4 Operadores

Para agrupar los operadores usados en los diferentes algoritmos he utilizado una clase **Operator** la cual tiene como métodos públicos los operadores usados en los algoritmos genéticos y meméticos.

2.4.1 Operadores de cruce

En este problema se han utilizado dos operadores de cruce, **Aritmético** y **BLX-α**

En ambos operadores, si los padres seleccionados son iguales, los hijos serán iguales a los padres.

El operador aritmético genera un aleatorio entre 0 y 1, para cada posición **i** de los padres, con el aleatorio escogido hace una combinación lineal distinta para cada hijo entre los genes de los padres. Si los genes de los padres son iguales en una determinada posición,

no se genera la transformación, de esta manera conseguimos que si todos los genes de los padres son iguales, los hijos sean iguales.

Al ser este cruce una combinación lineal, los genes de los hijos resultantes, nunca podrán tener un valor menor que el menor de los padres ni mayor que el mayor de los genes de sus padres. Esto hace que este operador tienda a converger hacia el centro de los padres, con un comportamiento explotativo.

```
# Pseudocódigo del operador Aritmético
 funcion arithmetic(padre1 , padre2):
   hijo1(padre1.size) ## genero los hijos con el mismo tamanio que los padres
   hijo2(padre1.size) ## en el problema que tratamos todos los cromosomas
miden lo mismo

   for i in range(0,tamaniopadres):

    if(padre1[i] == padre2[i]):
     # asigno el mismo gen a los hijos
     # de esta forma si los padres son idénticos
     # sus hijos también los son
     hijo1[i]=padre1[i]
     hijo2[i]=padre1[i]
    else:
     sigma = double aleatorio entre 0 y 1
     hijo1[i] =sigma*padre1[i]+(1-sigma)*padre2[i]
     hijo2[i] =sigma*padre2[i]+(1-sigma)*padre1[i]
   return pareja de hijos (hijo1, hijo2)
```

El operador BLX-alpha, genera un intervalo entre el minimo y el maximo de los genes seleccionados de los padres , a este intervalo se le añade un parámetro **alpha*gap**, el cual permite que el intervalo se agrande según el **alpha** escogido y la distancia entre el mínimo y el máximo.Esto permite que el valor aleatorio que se genere en ese intervalo para cada hijo , pueda ser más grande o más pequeño que los valores que el padre tenía por defecto por lo que permite explorar más soluciones y mantiene más diversidad ya que se generan genes que están fuera de los rango de los padres.

```
# Pseudocódigo del operador BLX-alpha
 funcion arithmetic(padre1 , padre2):
   hijo1(padre1.size) ## genero los hijos con el mismo tamanio que los padres
   hijo2(padre1.size) ## en el problema que tratamos todos los cromosomas
miden lo mismo

   for i in range(0,tamaniopadres):

    if(padre1[i] == padre2[i]):
     # asigno el mismo gen a los hijos
     # de esta forma si los padres son idénticos
     # sus hijos también los son
     hijo1[i]=padre1[i]
     hijo2[i]=padre1[i]
    else:
     cmax = double maximo entre padre1[i],padre2[i]
     cmin = double minimo entre padre1[i],padre2[i]
```

```
    gap = cmax-cmin
    hijo1[i] = aleatorio entre (cmin-gap*alpha,cmax+gap*alpha)
    hijo2[i] = aleatorio entre (cmin-gap*alpha,cmax+gap*alpha)
  return pareja de hijos (hijo1, hijo2)
```

Ambos operadores devuelven parejas de hijos que pueden no ser válidos por lo que se tendrán que arreglar ambos cuando estos se usen en los correespondientes algritmos.

2.4.2 Operador de selección

Para la selección de los padres se usa un torneo entre tres cromosomas elegidos al azar de la población actual.Estos tres cromosomas compiten por ver quien tiene mejor fitness y el que gane se convierte en padre.La función recibe como parametros el numero de seleccionados por torneo (k) ,el tamaño de la población,el número de padres que se deben de seleccionar , y el vector de fitness de la población , para economizar las evaluaciones.Como resultado la función devuelve un vector de indices de los cromosomas escogidos para ser padres.

```
# Pseudocódigo del operador tournament
 funcion tournament(tournamentsize ,
populationsize,selectionsize,fitnesspoblation):
  vector idxparents # vector con los indices de los padres
  # repito el torneo tantas veces como necesite
    for i in range(0,selectionsize):
      idxbest = 0

      for j in range(0,tournamentsize):
        idx = aleatorio entre 0 y populationsize-1
      #selecciono el mejor de entre los participantes del torneo
        if fitnesspoblation[idx] > fitnesstournament:
          fitnesstournament =fitnesspoblation
          dxbest = idx
      #añado el mejor del torneo a la lista de padres
      idxparents.puxhback(bestidx)
  return idxparents
```

2.4.3 Operador de mutación

A la hora de hacer la mutación en los algoritmos usaremos el siguiente método:

```
# Pseudocódigo del operador BLX-alpha
 funcion mutation(mutsol , problem ,mutationrate, maxattempts):
   idxgene=-1
   amount =0
   problembounds = pareja de valores de restriccion del problema #high,low

   for attempt in range(0,maxattempts):
     primercandidato = aleatorio entre (0,problem.size -1);
     amountcandidato = mutsol[primercandidato]*mutationrate
     # si la cantidad es 0 , busco otro ya que esta cantidad no
     # me modifica nada
```

```
     if(amountcandidato<=0):
       continue
     firstafter =mutsol[primercandidato]-amountcandidato
     bool firstvalido =firstafter == 0.0 || (firstafter >=
problembounds.first &&firstafter <= problembounds.second)

     if(firstvalido): #si puedo hacer la modificación al primero
      idxgene = primercandidato
      amount = candidateAmount
      break ## termino el bucle para buscar el primer gen
   if(idxGene ==-1):
    # si no he podido encontrar un primer gen en el rango de intentos que
tengo
    # no consigo mutar la solución y termino
    # esto no suele ocurrir , solo por seguridad
    return false

   idxnextgene=-1
   for attempt in range(0,maxattempts):
     segundocandidato = aleatorio entre (0,problem.size -1);

    ## si elijo el mismo que el primero busco otro
     if(idxGene ==segundocandidato):
       continue
     secondafter =mutsol[primercandidato]-amountcandidato
     bool secondvalido =secondafter == 0.0 || (secondafter >=
problembounds.first && secondafter <= problembounds.second)
     if(secondvalido): #si puedo hacer la modificación al segundo escoido
      idxnextgene = segundocandidato
      amount = candidateAmount
      break ## termino el bucle para dejar de buscar y aplicar la
modificación
   if(idxnextgene =-1):# si no consigo buscar un segundo gen ,no hago la
mutación
     return false
   ## Si todo ha ido bien aplico la mutación
  ## La mutación ya es valida ya que los genes
  ## modificados cumplen los límites de
  ## high y low y la suma total no cambia
   mutsol[idxgene]-=amount
   mutsol[idxnextgene]+=amount
   return true
```

La función de mutación recibe como parámetros la solución a mutar (por referencia), un objeto problema, el ratio de mutación y el número máximo de intentos que tenemos para elegir tanto el primer como el segundo gen.

Como se puede observar, el proceso de mutación se divide en dos partes:

- En el **primer bucle**, intentamos escoger un índice aleatorio para el primer gen a seleccionar; este gen debe cumplir las restricciones necesarias del problema tras haberle aplicado la transformación indicada. De no ser así, se genera otra posición aleatoria para el primer gen; este proceso se repite tantas veces como el parámetro `maxattempts` nos permita hasta conseguir un primer gen que acepte la transformación.

- Para el **segundo gen**, el proceso es similar: se busca un gen de forma aleatoria que pueda aceptar la suma de la cantidad que se va a restar del primer gen y que se mantenga en el rango de las restricciones del problema durante las iteraciones permitidas.

Cada vez que no se encuentra un gen que cumpla las restricciones y se hayan agotado las iteraciones permitidas, se devuelve `false`. De lo contrario, modifica la solución y se devuelve true. pasada por referencia se modifica. Esto se hace para poder tener un control posterior de cuándo se muta la solución.

3 Estructura de los algoritmos

3.1 Local Search

El algortimo de búsqueda local (el primero el mejor) parte de una solución generada aleatoriamente y genera un vecindario alrededor de esta solución , una vez generado el vecindario , se comienza a recorrer cada vecino y se evalúa su fitness. Si se encuentra un fitness mejor que el de la solución actual ,se escoge ese vecino como mejor solución y se genera un nuevo vecindario alrededor de el.El proceso termina cuando se llega al máximo de evaluaciones permitidas o cuando no se ha encontrado ningún vecino del vecindario actual generado que mejore la solución.

```
# Pseudocódigo del algoritmo de búsqueda local
función LocalSearch(max_evals):
    double ratio
    solucioninicial = solucionAleatoria
    bestfitnes = fitness(solucionAleatoria)

    vecinos = Generar vector de todas las parejas (i,j) posibles con i,j en
[0,ncompany-1]
    # excepto en el caso i=j;

    while evals < maxevals and haymejora:

      mezclar vecinos
      for v in vecinos:
        cantidadmover = ratio*solucioninicial[v.primero]

        solucioninicial[v.primero]-=cantidadmover
        solucioninicial[v.segundo]+=cantidadmover

        if es valida solucioninicial:
          evals = evals+1

          if fitness(solucioninicial) > mejorfitness:
            haymejora=true;
            mejorfitness=fitnes de la solucion inicial modificada
            #si hay una mejora salimos del bucle for
            #ya que es una busqueda del primero el mejor
            salir del bucle for
        # si no cambiamos de solucion inicial , hay que
        # devolverla a su estado original
        devolver solucioninicial a su estado original
        if evals==maxevals:
          salir del bucle for
          #para no pasarnos de evaluaciones
    return solucioninicial ,mejorfitness,evals
```

```
  #Generación del vecindario
  for i,j in ncompany:
    vectorparejas.insertar(pareja(i,j))
```

La implementación del algoritmo de Búsqueda local se divide en dos partes , primero se crea el vector vecinos , en este caso se usa un vector de parejas , donde cada vecino es la pareja (i,j) la cual nos indicará los índices que debemos modificar en el vector solución. Una vez creado el vector , lo mezclamos aleatoriamente , y este será el que nos indique qué vecinos debemos de probar. Si no fuese una busqueda de el primero el mejor y se escogiese el mejor vecino no haría falta mezclar las parejas ya que el orden no importaría por que siempre tendríamos que recorrer todo el vecindario.

Una vez disponemos del vecindario , debemos generar las nuevas soluciones a partir de las parejas que vamos escogiendo del vector , si tenemos la pareja (i,j) quitaremos un porcentaje del peso a la posición i y se la sumaremos a la posición j (el ratio usado en la práctica es 0.4). Esto nos genera una nueva solución la cual comprobaremos si es valida y en caso de ser valida si supera el fitness de nuestra mejor solución hasta el momento , este nuevo vector solución con las nuevas modificaciones en los indices (i,j) se convertirá en nuestra nueva solución. Dejaremos de recorrer el vector de vecinos y volveremos a generar un vecindario mezclado aleatoriamente para de nuevo recorrerlo desde el principio para ver si a partir de esta nueva solución generada , conseguimos una mejor.

Si la solución generada no es valida o no mejora la solución actual , restauraremos las modificaciones hechas al vector solución , de esta manera podemos usar un solo vector y modificar dos posiciones en vez de hacer copias de vectores completos.

Mientras que no se superen las restricciones de las evaluaciones y se sigan encontrando vecinos mejores en cada vecindario seguiremos intentando encontrar la mejor solución . En caso de recorrer todo el vecindario y no encontrar una solución mejor o que se superen las evaluciones permitidas , se detendrá la búsqueda.

3.2 Algoritmo Genético Generacional

Para el algoritmo genético Generacional , se ha construido una clase **Agg** para implementar la estructura del algoritmo , y dos clases hijas **AggArit** y **AggBLX** las cuales heredan de **Agg** y solo modifican la función de cruce. De esta manera podemos tener una única implementación del algoritmo y cambiar el operador de cruce con facilidad.

```
# Pseudocódigo del algoritmo de búsqueda local
función Agg(max_evals):
    evals = 0
    bestFitness = -infinito
    bestSolution
    poblation = soluciones aleatorias
    for i in range(0, populationSize):
      tempfitness = fitness(poblation[i])
      evals += 1
      fitnesspoblation.pushback(tempfitness)
      if tempfitness > bestFitness:
        bestFitness = tempfitness
        bestSolution = poblation[i]

    while evals < maxevals:
      tournament(tournamentsize, populationsize, populationsize,
fitnesspoblation)
```

```
      expectedparentscrossover = redondeo hacia arriba(crossoverprob *
idxparents.size())
      for i in range(0, expectedparentscrossover, 2):
        son = crossover(poblation[idxparents[i]], poblation[idxparents[i +
1]])
        reparar hijos inválidos
        sons.pushback(son.first)
        sons.pushback(son.second)

    for i in range(expectedparentscrossover, poblationsize):
      sons.pushback(poblation[idxparents[i]])

    ## mutación
    expectedmutation = mutationprob * populationsize
    for i in range(0, expectedmutation):
      idxsolution = random entre 0 y populationsize - 1
      mutsol = sons[idxsolution]
      mutation(mutSol, problem, 0.15, problemSize * 5)
      sons[idxSolution] = mutSol

    # Sustitución de la población
    for i in range(0, populationsize - 1):
      tempfitness = fitness(sons[i])
      evals += 1
      fitnesspoblation.pushback(tempfitness)
      if tempfitness > bestfitnessSons:
        bestfitnessSons = tempfitness
        idxbest = i
      if tempfitness < worstfitnessSons:
        worstFitnessSons = tempfitness
        idxworst = i
      if evals == maxevals:
        terminar
    if bestfitness > worstfitnesssons:
      sons[idxworst] = bestsolution
      fitnesspoblation[idxworst] = bestfitness
    if bestfitnessSons > bestfitness:
      bestsolution = sons[idxbest]
      bestfitness = bestfitnessSons
    poblation = sons
return bestsolution, bestfitness, evals
```

3.3 Algoritmo Genético Estacionario

Para el algoritmo genético Estacionari , se ha construido una clase **Age** para implementar la estructura del algoritmo , y dos clases hijas **AgeArit** y **AgeBLX** las cuales heredan de **Age** y solo modifican la función de cruce. De esta manera podemos tener una única implementación del algoritmo y cambiar el operador de cruce con facilidad.

3.4 Algortimo Memético

Para la implementación de los algoritmos meméticos he usado una clase llamada **Am** en la cual implemento el método optimize general , la busqueda local y el operador de cruce. Dentro de esta clase hay un método virtual **applyLocalSearch** que es el que marca la diferencia entre los tres tipos de algoritmo genético. Este método lo implementa cada subclase del algoritmo memético.A continuación describo el método applyLocalSearch que usa cada uno.

3.4.1 AM-Random

```
# Pseudocódigo de AM-Random (applyLocalSearch)
función applyLocalSearch(poblation, fitnesspoblation, bestFitness,
bestsolution, problem):
    nRand = redondeo hacia arriba(poblation.size() * 0.10)
    evals = 0
    for i in range(0, nRand):
      result = localSearch(problem, 100, poblation[i])
      evals += 100
      if result.fitness > fitnesspoblation[i]:
        fitnesspoblation[i] = result.fitness
        poblation[i] = result.solution
      if result.fitness > bestFitness:
        bestFitness = result.fitness
        bestsolution = result.solution
    return evals
```

3.4.2 AM-All

```
# Pseudocódigo de AM-All (applyLocalSearch)
función applyLocalSearch(poblation, fitnesspoblation, bestFitness,
bestsolution, problem):
    evals = 0
    for i in range(0, populationSize):
      result = localSearch(problem, 100, poblation[i])
      if result.fitness > fitnesspoblation[i]:
        fitnesspoblation[i] = result.fitness
        poblation[i] = result.solution
      if result.fitness > bestFitness:
        bestFitness = result.fitness
        bestsolution = result.solution
      evals += 100
    return evals
```

3.4.3 AM-Best

```
# Pseudocódigo de AM-Best (applyLocalSearch)
función applyLocalSearch(poblation, fitnesspoblation, bestFitness,
bestsolution, problem):
```

```
evals = 0
nBest = redondeo hacia arriba(populationSize * 0.10)
indices = indices de las nBest mejores soluciones según fitnesspoblation
for i in indices:
  result = localSearch(problem, 100, poblation[i])
  evals += 100
  if result.fitness > bestFitness:
    bestFitness = result.fitness
    bestsolution = result.solution
    poblation[i] = result.solution
return evals
```

4 Estructura del código

El código de la práctica está organizado en una estructura modular que facilita la compilación y ejecución. A continuación se describe la organización del proyecto y el manual de usuario para compilar y ejecutar el programa.

4.1 Organización de archivos

El proyecto está organizado de la siguiente manera:

- `software/` : Directorio raíz que contiene todo el código fuente
  - `main.cpp` : Archivo principal que ejecuta los algoritmos
  - `src/` : Contiene las implementaciones (.cpp)
    - `age.cpp` : Implementación del algoritmo AGE
    - `agg.cpp` : Implementación del algoritmo AGG
    - `amall.cpp` : Implementación del algoritmo AM-All
    - `ambest.cpp` : Implementación del algoritmo AM-Best
    - `amrand.cpp` : Implementación del algoritmo AM-Rand
    - `pportfolio.cpp` : Implementación de la clase del problema
    - `randomsearch.cpp` : Implementación del algoritmo de búsqueda aleatoria
    - `greedy.cpp` : Implementación del algoritmo Greedy
    - `localsearch.cpp` : Implementación del algoritmo de búsqueda local
    - `operator.cpp` : Implementación de la clase Operator
  - `include/` : Contiene los archivos de cabecera (.h y .hpp)
    - `age.h`: Clase base para los algoritmos genéticos estacionarios
    - `agg.h`: Clase base para los algoritmos genéticos generacionales
    - `agearit.h`, `ageblx.h`: Clases hijas de `age.h`con los correspondientes operadores
    - `aggarit.h`, `aggblx.h`: Clases hijas de `agg.h` con los correspondientes operadores
    - `amall.h`, `ambest.h`, `amrand.h`: Clases de los algoritmos meméticos.
    - `pportfolio.h`, `greedy.h`, `localsearch.h`, `randomsearch.h`
    - `operator.h` : Clase de operadores genéticos
    - `problem.h` : Clase base abstracta
    - `mh.h` : Clase base para los algoritmos de metaheurísticas
    - `solution.h` : Estructura para representar soluciones
    - `random.hpp`, `utils.hpp` : Utilidades auxiliares

  - `Eigen/` : Biblioteca para operaciones con matrices y vectores
- `data/` : Contiene los archivos CSV con los datos de entrada
- `CMakeLists.txt` : Archivo de configuración de CMake
- `script.sh` : Script de compilación automatizada
- `Makefile` : Archivo generado automáticamente por CMake

4.2 Compilación

El proyecto utiliza **CMake** como sistema de compilación automática. Se proporcionan dos modos de compilación:

Opción 1: Usando el script de compilación

El script **script.sh** automatiza el proceso de compilación:

```
# Para compilar en modo debug (con símbolos de depuración):
./script.sh debug

# Para compilar en modo release (optimización máxima):
./script.sh release
```

- **Modo debug**: Compila con la flag -O0 (sin optimización) y -g (símbolos de depuración), para detectar errores y depurar .
- **Modo release**: Compila con -O3 (máxima optimización) y -DNDEBUG (desactiva comprobaciones de Eigen),con esta compilación se han hecho las pruebas.

Opción 2: Usando CMake directamente

```
# Configurar el proyecto en modo release:
cmake CMakeLists.txt -DCMAKE_BUILD_TYPE=Release

# Compilar:
make
```

Tras cualquiera de estos procesos se generará el ejecutable **program** en el directorio software/.

4.3 Manual de usuario: Ejecución

Una vez compilado el programa, se puede ejecutar de las siguientes formas:

Ejecución estándar (comparación de algoritmos):

```
./program <ruta_archivo_csv> <low> <high> <evaluaciones> <seed> <output_csv>
```

Parámetros:

- **ruta_archivo_csv**: Ruta al archivo CSV con los datos de retornos diarios (ejemplo: data/portfolio.csv)
- **low**: Porcentaje mínimo de inversión permitido por empresa (ejemplo: 0.005)
- **high**: Porcentaje máximo de inversión permitido por empresa (ejemplo: 0.08)
- **evaluaciones**: Número de ejecuciones de cada algoritmo con diferentes seeds

- **seed**: Semilla inicial para el generador de números aleatorios (se incrementa en 10 por cada evaluación)
- **output_csv** : Archivo csv donde se guardan los fitness de todas las ejecuciones

El parámetro output_csv es opcional , si no se pone entonces no se guardan los datos en un fichero solo aparecen las medias.

Ejemplo de ejecución:

```
./program data/syp_100.csv 0.005 0.05 50 42 syp100.csv
```

Este comando ejecutará cada uno de los tres algoritmos (Random Search, Greedy y Local Search) 5 veces con seeds diferentes (42, 52, 62, 72, 82). Al finalizar mostrará para cada algoritmo:

- Fitness medio obtenido
- Fitness del año 2025
- Beneficio obtenido en el año 2025
- Número medio de evaluaciones realizadas
- Tiempo medio de ejecución (en segundos)

Al final creará un .csv con los datos de la ejecución

Ejecución simplificada (valores por defecto):

```
./program data/syp_100.csv 0.005 0.05
```

Ejecuta una sola evaluación con seed 42.

Ejecución de ayuda:

```
./program
```

Muestra el mensaje de ayuda con las instrucciones de uso.

5 Experimentos y análisis de los resultados

5.1 Casos empleados y valores de los parámetros.

Para comparar los resultados de los algoritmos se han usado los beneficios diarios de las empresas del S&P500 , S&P100 e IBEX35 con los siguientes parámetros.

- **λ**= 500 (usado en la función fitness)
- **seed** = 42 (por cada ejecución del algoritmo se incrementa 10 unidades)
- **low** = 0.005 (para todos los datos)
- **high**(para IB35) = 0.08
- **high**(para S&P100) = 0.05
- **high**(para S&P500) = 0.02
- **totalevaluations** = 50

La ejecución se ha hecho como se indicó en el apartado anterior , cambiando en los argumentos del programa el archivo de entrada de datos y ajustando su respectivo valor **high** correspondiente a cada archivo.

5.2 Resultados obtenidos

Algoritmo	**2015-2024 Fitness**	**2025 Fitness**	**Beneficio**	**Evaluaciones**	**Tiempo (segundos)**
Greedy	−4.649	−3.386	0.115	1	0.001
Random	−4.980	−3.289	0.096	10000	0.005
BL	−4.608	−3.109	0.019	1517.36	0.001
AGG-Arit	−4.613	−3.139	0.044	10000	0.004
AGG-BLX	−4.557	−3.220	0.071	10000	0.006
AGE-Arit	−4.572	−3.143	0.033	10000	0.002
AGE-BLX	−4.518	−3.139	0.052	10000	0.003
AM-ALL	−4.6538	−3.195	0.034	10000	0.004
AM-RAND	−4.944	−3.245	0.056	10000	0.006
AM-BEST	−4.510	−3.111	0.036	10000	0.004

Tabla 1: Resultados de Ibex 35 (Medias)

Algoritmo	**2015-2024 Fitness**	**2025 Fitness**	**Beneficio**	**Evaluaciones**	**Tiempo (segundos)**
Greedy	−3.663	−5.020	0.009	1	0.001
Random	−3.408	−3.968	0.069	10000	0.02
BL	−3.118	−3.918	0.094	8984.76	0.01
AGG-Arit	−3.006	−3.818	0.105	10000	0.027
AGG-BLX	−2.912	−3.838	0.141	10000	0.033
AGE-Arit	−3.128	−3.822	0.087	10000	0.012
AGE-BLX	−2.969	−3.703	0.111	10000	0.012
AM-ALL	−3.100	−3.863	0.041	10000	0.030
AM-RAND	−3.345	−3.858	0.097	10000	0.032
AM-BEST	−2.921	−3.799	0.110	10000	0.027

Tabla 2: Resultados de S&P100 (Medias)

Algoritmo	2015-2024 Fitness	2025 Fitness	Beneficio	Evaluaciones	Tiempo (segundos)
Greedy	−3.438	−5.204	−0.062	1	0.001
Random	−3.638	−4.606	−0.0583	10000	0.253
BL	−3.517	−4.313	0.018	10000	0.220
AGG-Arit	−3.090	−4.124	0.001	10000	0.443
AGG-BLX	−2.867	−4.042	0.002	10000	2.281
AGE-Arit	−3.358	−4.232	0.002	10000	0.202
AGE-BLX	−3.100	−4.208	−0.018	10000	0.184
AM-ALL	−3.236	−4.135	0.019	10000	0.334
AM-RAND	−3.542	−4.256	0.020	10000	0.690
AM-BEST	−2.857	−4.049	0.025	10000	1.035

Tabla 3: Resultados de S&P500 (Medias)

Los valores presentados en la tabla corresponden a las medias de 5 ejecuciones independientes con diferentes semillas aleatorias.

5.3 Boxplots de los resultados

A continuación se muestran los boxplots de los resultados obtenidos para cada conjunto de datos tras 50 ejecuciones de cada algoritmo:

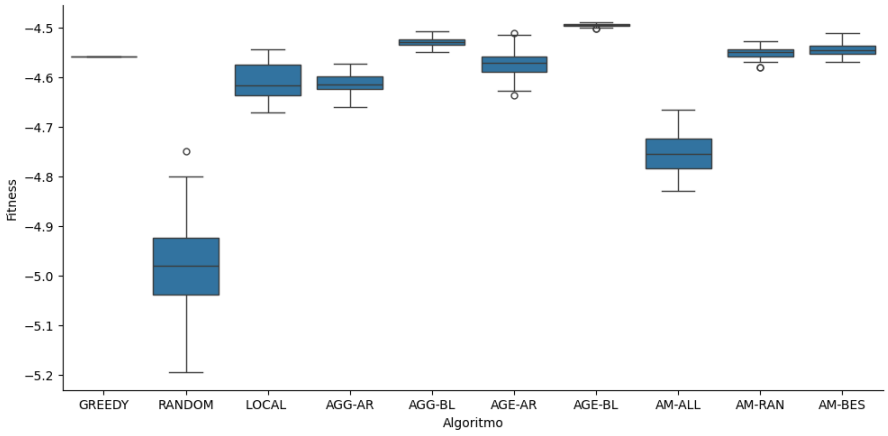


Figura 1: Boxplot de resultados para Ibex 35

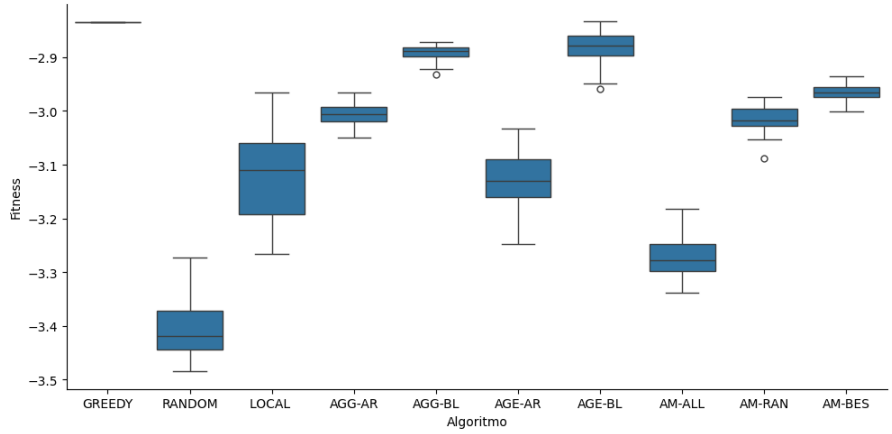


Figura 2: Boxplot de resultados para S&P100

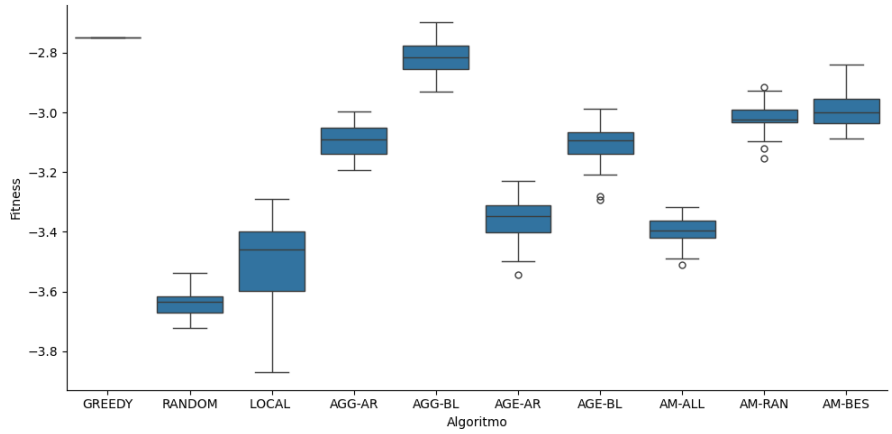


Figura 3: Boxplot de resultados para S&P500

6 Análisis de los resultados

Al observar los resultados obtenidos podemos ver que cada algoritmo se comporta de manera muy diferente dependiendo del conjunto de datos usado. Para poder entender por qué unos algoritmos funcionan mejor que otros es necesario analizar cómo trabaja cada uno y qué características del problema aprovechan o ignoran.

6.1 Comportamiento de los Algorítmos Genéticos Generacionales

Los AGG reemplazan en todas las iteraciones la población al completo, conservando el mejor de la población anterior e intercambiandolo por el peor de la generación que entra. Este tipo de reemplazo hace que haya más diversidad de soluciones y por tanto el algoritmo tenga menos riesgo de quedarse «atascado» en una zona del espacio de soluciones. Esto hace que el algoritmo explore más parte del espacio de soluciones, en consecuencia se pierden soluciones que aunque no fuesen la mejor , eran buenas y podrían haber convergido a mejores soluciones mediante cruces y mutaciones.

Podemos ver en el

6.2 Comportamiento de los Algorítmos Genéticos Estacionarios

6.3 Comportamiento de los Algorítmos Meméticos

6.4 Mejor operador para los genéticos

Como se puede observar en los resultados , en ambos algoritmos genéticos el mejor resultado lo obtiene el operador **BLX-α**.La principal diferencia entre este y el aritmético es que el **BLX-α** permite que el gen resultante de los hijos al cruzar los genes de los padres, pueda estar fuera del intervalo que genera el minimo y el máximo de los padres, por tanto los hijos resultantes de los cruces se pueden alejar más de sus padres y permiten explorar más el espacio de soluciones. Por otra parte , el cromosoma resultante del cruce aritmético contiene genes que no pueden tener un valor mayor o menor que el mayor o menor de los padres (al ser una combinación lineal) por lo que al aplicar este tipo de cruce , los hijos convergen a la media de los padres obteniendo mejor resultado en entornos explotativos.

6.5 Búsqueda Local vs Algorítmos Genéticos

Los algoritmos genéticos en el problema del portfolio , obtienen mejores resultados en el problema del portfolio ya que exploran más el espacio de soluciones que la búsqueda local. La búsqueda local es más explotativa por lo que le es fácil entrar en máximos locales en datasets pequeños como el ibex35 mientras que los algoritmos genéticos exploran un mayor rango de soluciones por lo que tienen más facilidad de evitar máximos locales. También cabe destacar que la búsqueda local se ve muy afectada por la solución inicial que se toma , al ser esta aleatoria , dependemos más de la «suerte» a la hora de encontrar una mejor solución antes de las evaluaciones permitidas. En los algorítmos genéticos también influye la población inicial , pero sobre todo en los AGG , al reemplazar toda la población en cada iteración y conservar la mejor solución , se consigue una mayor diversidad y mayor probabilidad de no quedarse atascado en un máximo local.

6.6 AGE-BLα vs AGG-BLα

6.7 Comparación entre meméticos

6.8 Meméticos vs mejor AG

6.9 Comparación Gráfica fitness 2014-2024 (50 ejecuciones)

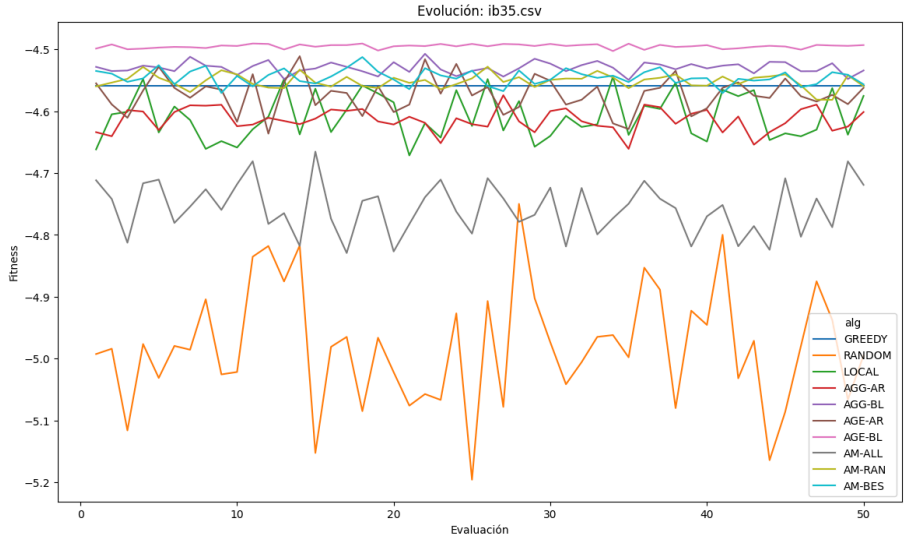


Figura 4: Comparación fitness para Ibex 35

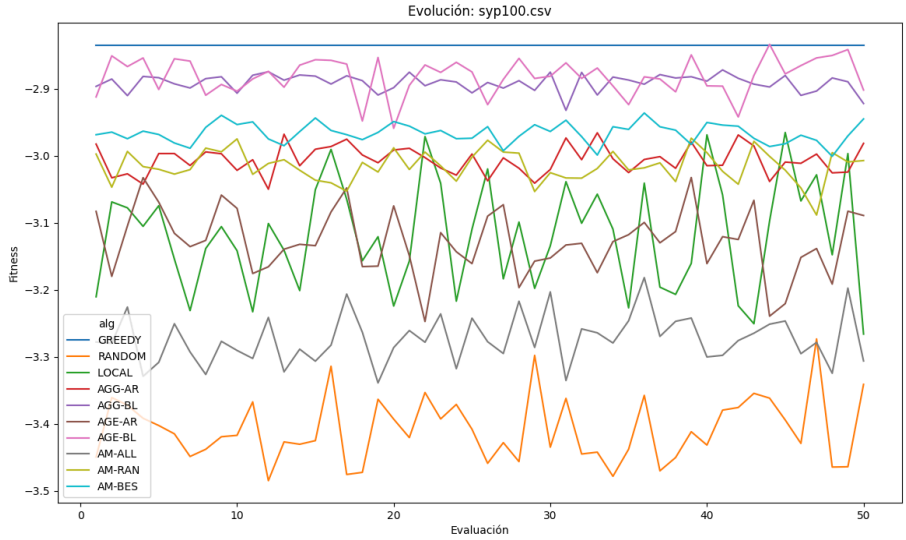


Figura 5: Comparación fitness para S&P100

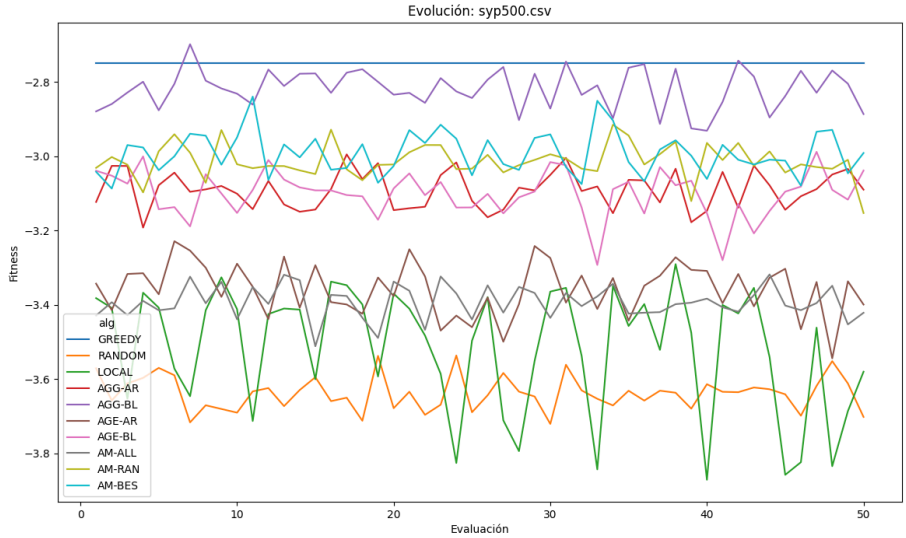


Figura 6: Boxplot de resultados para S&P500

En estas gráficas podemos ver la evolución del fitness a través de las 50 ejecuciones hechas , vemos que como es lógico en el Algoritmo Greedy se mantiene constante y podemos ver como la variabilidad del fitness va disminuyendo en el algoritmo de Búsqueda Aleatoria conforme el conjunto de datos aumenta , sin embargo la variabilidad del fitness de la búsqueda local sigue una distribución parecida en todos los casos.

Podemos observar también que en algunas ejecuciones la Búsqueda aleatoria ha obtenido mejor fitness que la Búsqueda Local , esto ocurre mayoritariamente en los datos del S&P500 ya que al ser un espacio de soluciones tan grande a la Búsqueda Local se le acaban las evaluaciones muy rápido y en algunos casos puede sacar fitness peores que la Búsqueda Aleatoria.

6.10 Comparación global y conclusiones